

# TRUE 框架模拟实验报告

本报告将 TRUE、Blind、MOO

三组在桥梁协同设计抽象任务上的表现进行了比较。

实验共进行 100 次 Monte Carlo 重复，每次 200

轮，外部专业工具全部被替换为模块级随机质量变量。

核心结论：

## 1. TRUE

在累积效用、平均质量和致命错误三个核心维度上都优于另外两组。

## 2. Blind

在安全性上最差，说明没有信任与约束机制时，资历偏见会显著放大事故风险。

## 3. MOO 虽然优于

Blind，但因为把信任直接作为目标，更容易出现选择集中和新人排斥。

## 4. TRUE

的优势主要来自“信任作为约束”而不是“信任作为目标”。

# 实验设计与建模假设

## 实验设计摘要

1. 任务生成：每轮随机抽取 3-5 个模块，并按依赖关系自动补全。
2. 外部工具替代：模块成功概率 =  $\text{capability} \times \text{difficulty}$ ；低能力承担致命模块时附加 10% 灾难性错误。
3. 效用函数：全部成功 +100；仅非致命失败 +60；任一致命失败 -200。
4. TRUE：Thompson 采样 + 信任/质量/可靠性底线 + 覆盖度鼓励。
5. Blind：无信任更新，偏向资深人类或随机分配。
6. MOO：把信任均值直接放入目标函数，不加安全底线。
7. 特殊实体：A8 代表可操纵 Agent；A9 第 50 轮加入；A10 第 100 轮加入。

# 组间汇总结果


| 组别    | 累积效用均值     | 平均质量  | 致命错误均值  | 成功率   | 信任Gini | 塌缩指数  | A9首次延迟  | A10首次延迟 |
|-------|------------|-------|---------|-------|--------|-------|---------|---------|
| Blind | -21485.400 | 0.384 | 178.160 | 0.354 | 0.601  | 0.361 | 7.270   | 9.040   |
| MOO   | -5788.400  | 0.678 | 96.040  | 0.621 | 0.749  | 0.454 | 999.000 | 999.000 |
| TRUE  | 1405.600   | 0.772 | 58.020  | 0.743 | 0.644  | 0.399 | 0.230   | 1.700   |

# 主要结论与假设支持情况


| 假设  | 结论   | 说明                      |
|-----|------|-------------------------|
| H1a | 支持   | TRUE 累积效用显著高于 Blind     |
| H1b | 支持   | TRUE 累积效用显著高于 MOO       |
| H2  | 基本支持 | MOO 的 Gini 和塌缩指数更高      |
| H3  | 支持   | TRUE 对 A9/A10 的接纳明显更快   |
| H4  | 部分支持 | 未复现强负相关，但 MOO 更易集中与排斥新人 |
| H5  | 支持   | TRUE 致命错误最少             |

# 核心绩效曲线

## Cumulative Utility by Round




## Cumulative Fatal Errors by Round




# 信任健康与结构塌缩

Selection Concentration (Gini Proxy)




Collapse Index




# 新 Agent 冷启动表现

## A9 Selection Rate After Join



## A10 Selection Rate After Join



# 结论与后续工作

## 结论与边界

### 1. TRUE

在本次近似仿真中表现最好，尤其在安全性和总效用上优势显著。

### 2. Blind 的失败主要体现为无约束分配导致的致命错误积累。

### 3. MOO

的主要问题不是完全失效，而是对高信任对象过度集中，并显著排斥新人。

### 4. A8 的 Goodhart

操纵效应只得到了部分复现，后续仍可加强其“高信任、低真实质量”的观测偏差设计。

### 5.

因此，这份报告最适合作为机制验证型结果，而不是工程系统的最终定量结论。