

TRUE 框架改进版

参数化场景族模拟实验报告

本报告面向当前不接入真实工具的约束条件，基于概率模型对多场景协作系统进行机制级评估。相较上一轮单场景实验，本轮将场景差异系统地编码进成功率、效用函数、观测污染和信任更新机制。

Monte Carlo 重复次数: 60

每次实验轮数: 200

比较对象: TRUE / Blind / MOO

执行摘要

本页用于给出管理层可快速读取的总体结论。

本轮实验的核心改进，是把原来的单一任务环境扩展成四类参数化场景，并明确区分真实质量、表面质量和最终观测信号。这样一来，实验不再只回答“TRUE 在一个默认环境里是否更好”，而开始回答“在高风险、观测污染、局部错位等不同环境下，TRUE 与 Blind、MOO 的相对优势是否稳定，以及这种优势具体来自哪些机制”。

整体来看，TRUE 在四类场景下都取得了最优或显著更优的综合表现：它在累积效用上持续领先，在致命错误上明显更低，同时对 A9/A10 这类新加入实体的接纳速度远快于 MOO。其中，Observation-Manipulated 场景最有力地展示了 MOO 在表面信号污染下的脆弱性；Utility-Trust-Misalignment 场景则说明了 TRUE 能更好地平衡短期收益与长期信息价值。

实验机理与建模逻辑

改进版实验与上一轮单场景实验的关键差别在于概率模型分层和场景参数化。

改进版实验在机理上引入了四项关键变化：

1. 三层质量结构：每个模块同时生成真实质量 q_{true} 、表面质量 q_{surface} 和最终观测 q_{obs} ，从而将“做得好”和“看起来好”区分开。

2.

条件依赖传播：上游模块失败会降低下游模块成功率，但高能力执行者可以部分修复依赖链上的损失。

3.

场景化效用函数：不同场景改变致命错误惩罚、观测权重、误差传播强度与局部阶段性收益结构。

4. 保持组间公平：TRUE、Blind、MOO

在相同任务流和相同场景参数下对比，只改变决策与信任机制。

场景族设计

本轮实验通过参数化概率模型来表达环境差异，而非更换任务领域。



四类场景分别覆盖了标准参考、高安全惩罚、观测污染和局部效用-信任错位四种关键机制。这样做的目的，是把“场景差异”直接落实到概率模型假设，而不是通过更换领域或接入外部工具来制造表面复杂度。

核心结果总表

四类场景 × 三组机制的主要结果指标。

场景	组别	累积效用	真实质量	表面质量	致命错误	成功率	选择Gini	塌缩指数	首次信任	质量相关
Baseline	Blind	-23558.33	0.341	0.404	209.050	0.315	0.528	0.317	5.800	0.000
Baseline	MOO	-2310.33	0.735	0.724	76.283	0.679	0.727	0.440	686.217	0.243
Baseline	TRUE	949.000	0.765	0.740	60.417	0.734	0.637	0.393	0.217	0.263
Safety-Criti	Blind	-53549.00	0.345	0.380	214.000	0.299	0.533	0.320	6.467	0.000
Safety-Criti	MOO	-5460.33	0.780	0.720	47.000	0.795	0.738	0.449	701.133	0.216
Safety-Criti	TRUE	-3530.00	0.794	0.722	41.817	0.813	0.655	0.415	0.467	0.107
Observation-Man	Blind	-24976.00	0.338	0.435	197.267	0.338	0.516	0.310	5.267	0.000
Observation-Man	MOO	-28912.00	0.218	0.876	224.700	0.269	0.858	0.515	999.000	0.003
Observation-Man	TRUE	1909.33	0.768	0.642	52.383	0.767	0.605	0.365	0.000	-0.023
Utility-Trust-Misa	Blind	-21554.33	0.336	0.390	204.100	0.311	0.530	0.318	6.783	0.000
Utility-Trust-Misa	MOO	-1233.33	0.713	0.701	74.883	0.685	0.728	0.439	654.033	0.305
Utility-Trust-Misa	TRUE	2885.83	0.751	0.708	53.783	0.762	0.608	0.375	0.383	0.286

主要统计检验

前 12 条检验结果。

场景	假设	指标	均值差	t值	近似p值	效应量d
Baseline	TRUE_A9 < Blind	first selected d	5.583	8.777	0.000	1.133
Baseline	TRUE_Collapse < MOO	collapse index	0.046	14.484	0.000	1.870
Baseline	TRUE_Fatal < Blind	fatal errors	148.633	82.088	0.000	10.597
Baseline	TRUE_Fatal < MOO	fatal errors	15.867	4.560	0.000	0.589
Baseline	TRUE_U > Blind	cumulative utili	24507.333	69.762	0.000	9.006
Baseline	TRUE_U > MOO	cumulative utili	3259.333	4.310	0.000	0.556
Safety-Critical	TRUE_A9 < Blind	first selected d	6.000	6.906	0.000	0.892
Safety-Critical	TRUE_Collapse < MOO	collapse index	0.034	10.841	0.000	1.400
Safety-Critical	TRUE_Fatal < Blind	fatal errors	172.183	100.781	0.000	13.011
Safety-Critical	TRUE_Fatal < MOO	fatal errors	5.183	3.368	0.001	0.435
Safety-Critical	TRUE_U > Blind	cumulative utili	50019.000	87.410	0.000	11.285
Safety-Critical	TRUE_U > MOO	cumulative utili	1930.333	2.970	0.003	0.383


主要统计检验（续）

剩余检验结果。

场景	假设	指标	均值差	t值	近似p值	效应量d
Observation-Manipulation	TRUE_A9 < Blind	first selected d	5.267	7.144	0.000	0.922
Observation-Manipulation	TRUE_Collapse < MOO	collapse index	0.150	106.758	0.000	13.782
Observation-Manipulation	TRUE_Fatal < Blind	fatal errors	144.883	74.618	0.000	9.633
Observation-Manipulation	TRUE_Fatal < MOO	fatal errors	172.317	65.255	0.000	8.424
Observation-Manipulation	TRUE_U > Blind	cumulative utility	26885.333	74.278	0.000	9.589
Observation-Manipulation	TRUE_U > MOO	cumulative utility	30821.333	97.182	0.000	12.546
Utility-Trust-Misalignment	TRUE_A9 < Blind	first selected d	6.400	6.926	0.000	0.894
Utility-Trust-Misalignment	TRUE_Collapse < MOO	collapse index	0.064	19.126	0.000	2.469
Utility-Trust-Misalignment	TRUE_Fatal < Blind	fatal errors	150.317	82.475	0.000	10.648
Utility-Trust-Misalignment	TRUE_Fatal < MOO	fatal errors	21.100	4.562	0.000	0.589
Utility-Trust-Misalignment	TRUE_U > Blind	cumulative utility	24440.167	87.282	0.000	11.268
Utility-Trust-Misalignment	TRUE_U > MOO	cumulative utility	4119.167	4.902	0.000	0.633





累积效用曲线

四类场景下 TRUE、Blind、MOO 的平均累积效用随轮数变化。







致命错误累积曲线

该页强调安全性差异，尤其用于对比 TRUE 的约束机制与 Blind/MOO 的风险暴露。



结构塌缩对比


该页重点刻画 MOO 在高信任目标化条件下更容易出现的选择集中和结构塌缩。




真实质量与表面质量

虚线表示表面质量，实线表示真实质量。Observation-Manipulated 场景中的分离最为明显。


Baseline




Safety-Critical



Observation-Manipulated



Utility-Trust-Misalignment



分场景结果解释

该页对四类场景的机制差异进行逐项解释，而不是仅重复数字。

Baseline：TRUE 的累积效用为 949.0，相比 Blind 高 24507.3，相比 MOO 高 3259.3。同时，TRUE 的致命错误均值为 60.4，低于 Blind 的 209.1 和 MOO 的 76.3。
这说明即使在标准参考环境下，约束式信任仍然优于盲目分配与信任目标化分配。

Safety-Critical：TRUE 的累积效用为 -3530.0，相比 Blind 高 50019.0，相比 MOO 高 1930.3。
同时，TRUE 的致命错误均值为 41.8，低于 Blind 的 214.0 和 MOO 的 47.0。高风险场景下三组整体效用都被大幅拉低，但 TRUE 仍然保持了更低事故数量和更快的新实体纳入速度。

Observation-Manipulated：TRUE 的累积效用为 1909.3，相比 Blind 高 26885.3，相比 MOO 高 30821.3。同时，TRUE 的致命错误均值为 52.4，低于 Blind 的 197.3 和 MOO 的 224.7。这一场景中，MOO 的表面质量均值高达 0.876，但真实质量仅为 0.218，清楚说明了将信任直接纳入目标函数会放大表面信号污染带来的误导。

Utility-Trust-Misalignment：TRUE 的累积效用为 2885.8，相比 Blind 高 24440.2，相比 MOO 高 4119.2。同时，TRUE 的致命错误均值为 53.8，低于 Blind 的 204.1 和 MOO 的 74.9。MOO 对 A9 的首次接纳延迟达到 654.0，而 TRUE 仅为 0.4，表明 TRUE 更能容纳“短期不占优但长期有价值”的低历史实体。

结论与后续工作

下一步建议在此基础上补 protocol、参数敏感性分析和更正式的统计稳健性检验。

本轮改进版实验说明，TRUE 的优势并不依赖单一默认场景，而是在多种概率模型环境中都表现出稳定性。当环境更强调安全约束时，TRUE 可以更好地压住事故；当环境存在观测污染时，TRUE 能更有效地区分真实质量和表面质量；当局部阶段存在短期效用、当前信任与长期信息价值的不一致时，TRUE 仍然能够更快接纳高潜力低历史实体。

更重要的是，这份报告把“场景差异来自哪里”交代得更清楚：场景差异不来自领域切换，而来自概率模型、效用结构、观测结构和更新规则的改变。这使得后续继续做敏感性分析、协议固定和机制扩展会更加顺畅。